PROYECTO FINAL DE ESPECIALIDAD

Big Data e Inteligencia Artificial

Optimizador de Precios para Apartamentos Turísticos en Barcelona

1r Corte

IFP — Innovación en Formación Profesional

1. Explicación y Detalles de los Datos

1.1 Introducción al Proyecto

El presente proyecto tiene como finalidad desarrollar un sistema de optimización de precios para apartamentos turísticos en la ciudad de Barcelona, apoyado en técnicas de Big Data e Inteligencia Artificial. El modelo resultante deberá ser capaz de predecir el precio óptimo por noche para un alojamiento dado, cruzando datos históricos de ocupación y características de los anuncios con variables externas como el clima local y la celebración de eventos en la ciudad.

La motivación de este enfoque reside en que el precio de un apartamento turístico no depende únicamente de sus características físicas (superficie, número de habitaciones, barrio), sino que está fuertemente influenciado por el contexto temporal y el entorno: una semana con un gran festival o un episodio de lluvias persistente puede alterar significativamente la demanda y, por tanto, el precio de mercado. El objetivo final es proporcionar una herramienta útil para que los propietarios de apartamentos tomen decisiones de precio basadas en datos.

1.2 Fuentes de Datos

1.2.1 Inside Airbnb — Listings y Calendar de Barcelona

Inside Airbnb (http://insideairbnb.com) es un proyecto independiente que recopila y publica datos extraídos de la plataforma Airbnb con el objetivo de facilitar el análisis del impacto del alquiler turístico en las ciudades. Los datos se publican bajo la licencia Open Database License (ODbL), que permite su uso, distribución y modificación libre siempre que se mantenga la misma licencia en los trabajos derivados. El uso de estos datos con fines académicos es plenamente compatible con dicha licencia.

Se utilizan dos ficheros principales:

- listings.csv: contiene información descriptiva de cada anuncio activo en Barcelona. Cada fila representa un apartamento o habitación publicado en Airbnb. Las columnas más relevantes para el proyecto son:

Campo	Tipo	Descripción
id	Numérico	Identificador único del anuncio
name	Texto	Título del anuncio tal como aparece en Airbnb
host_id	Numérico	Identificador del anfitrión
neighbourhood_cleansed	Categórico	Barrio del alojamiento (estandarizado)
latitude / longitude	Numérico	Coordenadas geográficas del alojamiento
room_type	Categórico	Tipo: Entire home, Private room, Shared room, Hotel room
accommodates	Numérico	Número máximo de huéspedes

Campo	Tipo	Descripción
bedrooms / beds	Numérico	Número de dormitorios y camas
bathrooms_text	Texto	Descripción del número de baños
amenities	Texto (lista)	Servicios incluidos (WiFi, cocina, parking, etc.)
price	Numérico (texto)	Precio por noche publicado (en dólares, requiere limpieza)
minimum_nights	Numérico	Mínimo de noches por reserva
number_of_reviews	Numérico	Total de reseñas recibidas
review_scores_rating	Numérico	Puntuación media de los huéspedes (0-5)
availability_365	Numérico	Días disponibles en el próximo año

- calendar.csv: registra la disponibilidad y el precio de cada anuncio para cada día del año. Es la fuente principal para el análisis temporal de ocupación y precios. Las columnas clave son:

Campo	Tipo	Descripción
listing_id	Numérico	Clave foránea que enlaza con listings.csv
date	Fecha	Día concreto al que corresponde el registro
available	Booleano (t/f)	Indica si el apartamento está disponible ese día
price	Numérico (texto)	Precio publicado para ese día (puede diferir del precio base)
minimum_nights	Numérico	Mínimo de noches aplicable para esa fecha concreta
maximum_nights	Numérico	Máximo de noches permitido para esa fecha

El volumen aproximado del fichero calendar.csv para Barcelona supera los 10 millones de registros, lo que justifica el uso de herramientas de Big Data para su procesamiento eficiente.

1.2.2 Open-Meteo — Datos Climáticos Históricos

Open-Meteo (https://open-meteo.com) es un servicio de datos meteorológicos de código abierto que proporciona datos históricos y pronósticos a través de una API REST. Se distribuye bajo licencia CC BY 4.0, lo que permite su uso libre con atribución. La API permite descargar series temporales diarias de variables como temperatura máxima y mínima, precipitación acumulada y velocidad del viento para coordenadas geográficas concretas.

Para este proyecto se extraerán datos climáticos históricos correspondientes a las coordenadas de Barcelona (lat: 41.3828, lon: 2.1769) para el período temporal cubierto por el dataset de Airbnb. Las variables seleccionadas son:

Variable	Unidad	Relevancia para el modelo
temperature_2m_max	°C	Las altas temperaturas correlacionan con mayor demanda turística estival
temperature_2m_min	°C	Complementa el rango térmico diario
precipitation_sum	mm	La lluvia puede reducir la demanda de alojamiento turístico
windspeed_10m_max	km/h	Vientos fuertes afectan a actividades al aire libre y playas
weathercode	Código WMO	Clasificación general del tiempo (soleado, nublado, lluvia, tormenta)

1.2.3 Ticketmaster API — Eventos en Barcelona

Ticketmaster dispone de una API pública (https://developer.ticketmaster.com) de acceso gratuito previo registro como desarrollador. Permite consultar eventos de música, deportes, teatro y otros espectáculos por ciudad y rango de fechas. El uso de la API con fines académicos y no comerciales es compatible con los términos de servicio de la plataforma.

La incorporación de esta fuente responde a la hipótesis de que la celebración de grandes eventos en Barcelona (conciertos multitudinarios, partidos del FC Barcelona, ferias, festivales como el Sónar o el Primávera Sound) provoca picos de demanda de alojamiento que se reflejan en un incremento de precios. Los campos de interés son:

Campo	Tipo	Descripción
name	Texto	Nombre del evento
dates.start.localDate	Fecha	Fecha de inicio del evento
classifications.segment.name	Categórico	Categoría: Music, Sports, Arts, etc.
_embedded.venues.city.name	Texto	Ciudad del evento (filtrado por Barcelona)
priceRanges.min / max	Numérico	Rango de precios de las entradas (indicador de magnitud del evento)

2. Selección e Integración de Datasets

2.1 Tipología de Variables

Para estructurar correctamente el análisis estadístico, es necesario clasificar las variables de los datasets según su naturaleza. A continuación se presenta la clasificación de las variables principales que intervendrán en el modelo:

Variable	Dataset	Tipo	Escala
price (diario)	calendar.csv	Cuantitativa continua	Ratio
available	calendar.csv	Cualitativa dicotómica	Nominal
room_type	listings.csv	Cualitativa nominal	Nominal
neighbourhood_cleansed	listings.csv	Cualitativa nominal	Nominal
accommodates	listings.csv	Cuantitativa discreta	Ratio
bedrooms / beds	listings.csv	Cuantitativa discreta	Ratio
review_scores_rating	listings.csv	Cuantitativa continua	Intervalo
number_of_reviews	listings.csv	Cuantitativa discreta	Ratio
availability_365	listings.csv	Cuantitativa discreta	Ratio
temperature_2m_max	Open-Meteo	Cuantitativa continua	Intervalo
precipitation_sum	Open-Meteo	Cuantitativa continua	Ratio
weathercode	Open-Meteo	Cualitativa ordinal	Ordinal
event_category	Ticketmaster	Cualitativa nominal	Nominal
event_count_day	Ticketmaster	Cuantitativa discreta	Ratio

2.2 Modelo Relacional e Integración de Tablas

La integración de los cuatro datasets se articula en torno a dos ejes de unión: el identificador del anuncio (listing_id) y la fecha (date). El esquema conceptual de relaciones es el siguiente:

```
                    listings.csv
(id, room_type, neighbourhood, accommodates, …)
                  ↓ id = listing_id
                    calendar.csv
(listing_id, date, available, price)
                  ↓ date = date
clima_barcelona.csv  +  eventos_barcelona.csv
(date, temperatura, precipitación, …)        (date, n_eventos, categoría, …)
```

El proceso de integración se llevará a cabo en Python (pandas) mediante operaciones de JOIN. Primero se unirá calendar.csv con listings.csv a través de listing_id, obteniendo un dataset enriquecido con las características del alojamiento. A continuación, se incorporarán las variables climáticas y de eventos mediante un LEFT JOIN sobre la columna date, de manera que cada registro diario del calendario quede asociado con las condiciones meteorológicas y el número de eventos celebrados en Barcelona ese día.

El dataset integrado final tendrá como unidad de análisis la combinación «listado-día», con una variable objetivo continua (price) y un conjunto de variables predictoras de distinta naturaleza (características del alojamiento, temporalidad, clima y eventos).

2.3 Análisis Estadístico Previsto

Durante la fase de comprensión y preparación de los datos, se aplicarán los siguientes tipos de análisis estadístico:

Estadística descriptiva: se calcularán medidas de tendencia central (media, mediana) y de dispersión (desviación típica, percentiles) para la variable price, tanto a nivel global como desagregado por barrio, tipo de alojamiento y mes del año. El objetivo es detectar asimetrías, valores atípicos (outliers) y patrones estacionales.

Análisis de correlación: se utilizará el coeficiente de correlación de Pearson para cuantificar la relación lineal entre el precio y las variables numéricas (número de camas, temperatura, número de eventos). Para variables categóricas se empleará el coeficiente V de Cramér.

Análisis de varianza (ANOVA): se comparará la media de precio entre grupos (room_type, neighbourhood_cleansed) para determinar si las diferencias son estadísticamente significativas.

Análisis de series temporales: se visualizará la evolución del precio medio a lo largo del tiempo para identificar tendencias, estacionalidad (mayor precio en verano) y picos asociados a eventos concretos.

Detección de outliers: se aplicará el método del rango intercuartílico (IQR) para identificar y tratar los precios anómalamente altos o bajos que podrían distorsionar el modelo predictivo.

3. Metodología de Minería de Datos

3.1 Justificación de la Metodología Seleccionada

Para estructurar el proceso de análisis y modelado del presente proyecto se ha adoptado la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining). Esta elección se justifica por varios motivos. En primer lugar, CRISP-DM es el estándar más extendido en la industria para proyectos de minería de datos y aprendizaje automático, con una trayectoria consolidada desde su publicación en 1999. En segundo lugar, su carácter cíclico e iterativo se adapta perfectamente a un proyecto en el que el entendimiento de los datos y el refinamiento del modelo se producen de forma progresiva a lo largo del curso.

Frente a alternativas como SEMMA (Sample, Explore, Modify, Model, Assess) o KDD (Knowledge Discovery in Databases), CRISP-DM ofrece una fase de «Comprensión del Negocio» explícita que resulta especialmente valiosa en este proyecto, dado que el problema de optimización de precios requiere entender las dinámicas del mercado de alquiler turístico antes de proceder al análisis técnico.

3.2 Fases del Proceso CRISP-DM Aplicadas al Proyecto

Fase 1: Comprensión del Negocio

El objetivo de negocio es proporcionar una estimación del precio óptimo por noche para un apartamento turístico en Barcelona en función de sus características y del contexto temporal. Las preguntas clave que guían el proyecto son:

- ¿Qué variables tienen mayor influencia sobre el precio de un apartamento turístico en Barcelona?
- ¿Existe una correlación significativa entre la celebración de eventos y el incremento de precios?
- ¿Cuál es el impacto de las condiciones climáticas sobre la ocupación y los precios?
- ¿Qué barrios de Barcelona presentan mayor variabilidad de precios a lo largo del año?

El criterio de éxito del modelo se define como la capacidad de predecir el precio de un alojamiento con un error cuadrático medio (RMSE) inferior al 20% del precio medio del mercado.

Fase 2: Comprensión de los Datos

Esta fase comprende la descarga, inspección y exploración inicial de los tres datasets descritos en la sección 1. Las actividades principales son: análisis de la estructura de cada fichero (número de filas, columnas y tipos de datos), identificación de valores nulos y duplicados, cálculo de estadísticos descriptivos básicos y generación de visualizaciones exploratorias (histogramas de precios, mapas de calor por barrio, series temporales de disponibilidad).

Esta fase se llevará a cabo principalmente con Python (pandas y matplotlib) y será complementada con análisis en R (ggplot2) para la visualización estadística.

Fase 3: Preparación de los Datos

La preparación de los datos engloba todas las transformaciones necesarias para que el dataset integrado sea apto para el modelado. Las tareas previstas son:

1. Limpieza de la variable price: eliminación del símbolo monetario y conversión a tipo numérico.
2. Tratamiento de valores nulos: imputación por la mediana para variables numéricas y por la moda para variables categóricas.
3. Detección y tratamiento de outliers en la variable objetivo (price) mediante el método IQR.
4. Codificación de variables categóricas: one-hot encoding para room_type y label encoding para neighbourhood_cleansed.
5. Extracción de características temporales a partir de la columna date: mes, día de la semana, si es fin de semana, si es temporada alta.
6. Integración de los datasets mediante JOIN en Python y posterior carga en BigQuery para el análisis a escala.

Fase 4: Modelado

El modelado se realizará íntegramente en Orange Data Mining, aprovechando su interfaz gráfica para construir y comparar distintos algoritmos de regresión. Los modelos que se evaluarán son: Regresión Lineal Múltiple (como línea base), Árbol de Decisión para Regresión, Random Forest y Gradient Boosting. La variable objetivo es el precio diario del anuncio y las variables predictoras son el conjunto de características del alojamiento, temporales, climáticas y de eventos definidas en la sección 2.

Fase 5: Evaluación

Los modelos se evaluarán mediante validación cruzada de 10 pliegues (10-fold cross-validation) para garantizar la robustez de los resultados. Las métricas empleadas serán el Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE) y el coeficiente de determinación (R^2). Se seleccionará el modelo con menor RMSE como modelo final, siempre que su complejidad sea interpretable.

Fase 6: Despliegue

Los resultados del modelo se presentarán mediante un dashboard interactivo en Power BI que permitirá visualizar las predicciones de precio por barrio, tipo de alojamiento y período temporal. El informe final, el código fuente y la documentación del proyecto se publicarán en un repositorio de GitHub estructurado según las indicaciones del proyecto.

3.3 Stack Tecnológico Seleccionado

En coherencia con la metodología descrita y con los requisitos del proyecto, se han seleccionado las siguientes herramientas y tecnologías:

Python (pandas, matplotlib): se utilizará para las fases de comprensión y preparación de los datos. Pandas ofrece estructuras de datos óptimas para la manipulación de ficheros CSV de gran tamaño, mientras que matplotlib proporcionará las visualizaciones exploratorias necesarias.

BigQuery (SQL): se empleará como repositorio central del dataset integrado y como motor de consultas SQL para los análisis de agregación a escala (precios medios por barrio y mes, tasas de ocupación, etc.). Su capacidad para procesar grandes volúmenes de datos sin infraestructura local lo convierte en la opción idónea para la capa de almacenamiento y consulta del proyecto.

Orange Data Mining: se utilizará para la construcción visual del pipeline de aprendizaje automático. Su interfaz basada en flujos de trabajo permite comparar múltiples algoritmos de regresión de forma intuitiva y reproducible, y generar las curvas de evaluación necesarias para la selección del modelo final.

Power BI: será la herramienta de visualización y presentación de resultados. Se creará un dashboard interactivo que permitirá filtrar las predicciones de precio por barrio, tipo de alojamiento y rango de fechas, facilitando la toma de decisiones a los propietarios.

Bibliografía y Fuentes de Datos

Inside Airbnb. (2024). Barcelona Listings & Calendar Dataset. Recuperado de http://insideairbnb.com/barcelona [Licencia: ODbL]

Open-Meteo. (2024). Historical Weather API Documentation. Recuperado de https://open-meteo.com/en/docs/historical-weather-api [Licencia: CC BY 4.0]

Ticketmaster. (2024). Developer API — Discovery API v2. Recuperado de https://developer.ticketmaster.com/products-and-docs/apis/discovery-api/v2/

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining, 1, 29-39.