Apuntes detallados para defensa — Predictor de Ocupación Barcelona

Este documento es para empollar. Cubre todos los conceptos del proyecto con explicaciones didácticas, las preguntas más probables del profesor con respuestas extensas y frases preparadas para defender cada decisión técnica.

Índice

1. Glosario de términos clave
2. El proyecto en 30 segundos
3. CRISP-DM fase a fase con detalle
4. Los tres modelos explicados
5. Métricas de evaluación con explicación didáctica
6. Las 25 preguntas más probables del profesor
7. Frases preparadas para defender decisiones

---

1. Glosario de términos clave

Término	Qué es	Ejemplo del proyecto
CRISP-DM	Cross-Industry Standard Process for Data Mining. Metodología estándar de 6 fases.	Estructura todo el proyecto.
Clasificación binaria	Predecir entre dos clases (0/1).	Predecir si una noche estará ocupada o libre.
Variable target	Lo que queremos predecir.	occupied.
Features	Variables que el modelo usa para predecir.	Las 56 columnas del dataset modelado.
Train / Test	División del dataset: train para entrenar, test para evaluar.	758k filas train, 254k filas test.
Split temporal	Dividir train/test por fecha en lugar de aleatorio.	Primeros 42 días train, últimos 14 test.
Leakage (fuga de información)	Cuando una feature contiene información del target.	availability_* proxy directo de occupied.
Target encoding	Codificar una categoría como la media del target en ese grupo.	listing_te, neigh_enc.
One-hot encoding	Codificar una categoría con	room_type → 4 columnas

	N valores en N columnas binarias.	binarias.
Class weight	Peso aplicado a cada clase para equilibrar desbalanceos.	Quitado para mejorar F1.
Hiperparámetro	Parámetro del modelo que se elige antes de entrenar.	n_estimators=200, max_depth=15.
Ensemble	Combinación de varios modelos simples.	Random Forest = ensemble de árboles.
Bagging	Técnica de ensemble: entrenar modelos sobre subconjuntos aleatorios.	Random Forest.
Boosting	Técnica de ensemble: cada modelo corrige errores del anterior.	Gradient Boosting.
Threshold	Umbral de probabilidad para decidir la clase.	Default 0.5.
Accuracy	Porcentaje de aciertos sobre el total.	0.812 (81%).
Precision	De los que predigo positivos, cuántos lo son de verdad.	78.7% en RF.
Recall	De los positivos reales, cuántos detecto.	84.2% en RF.
F1-score	Media armónica de precision y recall.	0.812 en RF.
AUC-ROC	Área bajo la curva ROC. Capacidad discriminativa.	0.895 en RF.
MCC	Matthews Correlation Coefficient. Métrica robusta para binaria.	0.627 en RF.
Matriz de confusión	Tabla 2x2 con TP/FP/TN/FN.	TP=104k, TN=102k, FP=28k, FN=20k.
TP, TN, FP, FN	True/False Positive/Negative.	Aciertos y errores por tipo.
ROC	Curva que muestra TPR vs FPR para todos los thresholds.	Casi pegada a la esquina superior izquierda.
Cold start	Problema de predecir para entidades nuevas sin historial.	Listings nuevos sin listing_te.

Confounding	Variable oculta que media la relación entre dos variables.	Lluvia-ocupación mediada por la fecha.
EDA	Exploratory Data Analysis.	Notebook 02.
Pivot del proyecto	Cambio de objetivo a mitad de proyecto.	Precio → Ocupación.
Data warehouse	Base de datos cloud para análisis.	Google BigQuery.
DAX	Lenguaje de fórmulas de Power BI.	% Ocupación = AVERAGE(…).
Slicer	Filtro interactivo en Power BI.	Slicer temporal, slicer de segmento.

2. El proyecto en 30 segundos

> *"Predictor de ocupación de apartamentos turísticos en Barcelona. Clasificación binaria supervisada. Predigo, para cada combinación piso-día, si ese día estará reservado o bloqueado. El target es la columna occupied derivada del calendario público de Inside Airbnb. El proyecto integra cuatro fuentes (Inside Airbnb, Open-Meteo, Ticketmaster, festivos catalanes) en un dataset de 1 millón de filas. Compara tres modelos (Logistic Regression, Random Forest, Gradient Boosting) en dos plataformas (scikit-learn y Orange Data Mining), almacena los resultados en BigQuery y los presenta en un dashboard interactivo de Power BI. El modelo ganador, Random Forest, obtiene AUC=0.895 y F1=0.812, superando los umbrales del curso."*

---

3. CRISP-DM fase a fase con detalle

CRISP-DM (Cross-Industry Standard Process for Data Mining) es la metodología estándar para proyectos de ciencia de datos. Define 6 fases secuenciales pero iterativas.

Fase 1: Business Understanding

Pregunta que responde: ¿Qué problema queremos resolver y por qué?

Lo que hice: - Definí el problema original: Predictor de Precio Óptimo (regresión sobre price). - Establecí métricas de éxito: F1 ≥ 0.75 y AUC ≥ 0.80. - Tras la fase 2 detecté que price estaba vacía y reformulé el problema a clasificación binaria sobre occupied.

Decisión clave: El pivot del proyecto. Es importante porque demuestra que hay análisis crítico antes de implementar, no implementación a ciegas. Los proyectos reales se reorientan constantemente cuando los datos no son lo esperado.

Fase 2: Data Understanding

Pregunta que responde: ¿Qué datos tenemos y qué nos cuentan?

Lo que hice: - EDA completo en el notebook 02 sobre las cuatro fuentes. - Estadísticos descriptivos de listings.csv: 18.172 pisos, distribución por barrio, room_type, etc. - Análisis de calendar.csv: ~5,3 millones de filas, distribución de available='t' vs 'f'. - Visualización de la serie temporal del clima. - Cálculo de correlaciones diarias entre clima/eventos y ocupación.

Tres hallazgos críticos documentados: 1. **Columna price vacía.** Inside Airbnb dejó de publicarla en 2024 por restricciones legales. Motiva el pivot. 2. **Ambigüedad de available='f'.** Mezcla noches reservadas con noches bloqueadas por el anfitrión sin distinción. Se mitiga limitando el modelo a 8 semanas posteriores al scrape. 3. **Desfase temporal de Ticketmaster.** Los eventos disponibles cubren Abr-Jul 2026, sin solapamiento con el horizonte del modelo (Dic 2025-Feb 2026). Se descarta como feature.

Fase 3: Data Preparation

Pregunta que responde: ¿Cómo dejamos los datos listos para modelar?

Lo que hice (notebooks 03 y 04):

Limpieza por fuente: - listings.csv: filtrado a 25 columnas útiles, conversión booleanos textuales t/f a 1/0, imputación de nulos en bedrooms/bathrooms por mediana de barrio. - calendar.csv: filtrado al horizonte de 56 días, creación de la variable occupied, generación de features temporales (dow, is_weekend, month, day, week, is_holiday). - clima_barcelona.csv: categorización del weathercode en cuatro categorías (soleado, nublado, lluvia, extremo) basadas en códigos WMO. Cálculo de temp_avg. - eventos_barcelona.csv: limpieza pero no integración en el modelo principal.

Integración: - Join secuencial: calendar_clean ⋈ listings_clean (LEFT JOIN por listing_id) → ⋈ clima_clean (LEFT JOIN por date). - Resultado: dataset_integrado.csv con 1.012.783 filas × 40 columnas y cero nulos. - Granularidad: una fila por combinación listing × día.

Decisiones clave: - **Limitación a 8 semanas post-scrape.** Mitiga el sesgo de bloqueos de anfitrión que dominan en horizontes largos. - **Eliminación de eventos del modelo.** Por desfase temporal documentado, se mantiene como tabla auxiliar.

Fase 4: Modeling

Pregunta que responde: ¿Qué algoritmos usamos y con qué hiperparámetros?

Lo que hice (notebook 05 + Orange):

Estrategia de evaluación: - Split temporal en 2026-01-25: train = 42 días (758.375 filas), test = 14 días (254.408 filas). - Por qué temporal: simula predicción real (entrenar con pasado, evaluar con futuro). El test cae además fuera de temporada alta, lo que añade exigencia.

Feature engineering crítico: - **Anti-leakage:** drop de availability_30/60/90/365 y estimated_occupancy_l365d. Vienen del propio calendar y son proxies directos del target. - **Target encoding:** cálculo de neigh_enc (media de occupied por barrio en train) y

listing_te (media por listing). Solo con datos de train para evitar data leakage hacia test. - **One-hot encoding:** de room_type, property_type, weather_cat, neighbourhood_group_cleansed.

Tres modelos entrenados (ver sección 4 para detalle).

Plataforma dual: - **scikit-learn** (notebook 05): implementación programática con control fino. - **Orange Data Mining** (pipeline_ocupacion.ows): pipeline visual con widgets para validación cruzada.

Fase 5: Evaluation

Pregunta que responde: ¿Cuán bien funciona el modelo?

Métricas finales sobre el conjunto de test (254.408 filas):

Modelo
Random Forest
Gradient Boosting
Logistic Regression

Cumplimiento de umbrales del curso: - F1 ≥ 0.75 ✓ en los tres modelos. - AUC ≥ 0.80 ✓ en los tres modelos.

Matriz de confusión del Random Forest:

Real libre (0)	
Real ocupado (1)	

- TN: 102.473 → 78,4% de los libres reales.
- FP: 28.209 → 21,6% de los libres reales (errores tipo I).
- FN: 19.524 → 15,8% de los ocupados reales (errores tipo II).
- TP: 104.202 → 84,2% de los ocupados reales.

Importance del Random Forest: - listing_te: 0.66 (dominante). - reviews_per_month, latitude, longitude, number_of_reviews: 0.03-0.07 cada una. - Resto de features: <0.03.

Fase 6: Deployment

Pregunta que responde: ¿Cómo lo ponemos en manos del usuario?

Lo que hice:

Subida a BigQuery: - Script sql/subir_dataset.py. - Carga dataset_integrado.csv a price-optimizer-bcn.datos.fact_ocupacion. - Auto-detección de esquema, modo Importar, free tier.

Tres queries SQL de KPI: - ocupacion_por_barrio.sql: ranking dual con UNION ALL (segmento todo vs entire_home, umbral listings ≥ 30). - ocupacion_por_room_type.sql: KPI por categoría con efecto Navidad vs resto. - ocupacion_por_clima.sql: 3 vistas (categoría, temperatura, lluvia) agregadas a nivel día.

Dashboard Power BI (dashboard_ocupacion.pbix): - Conexión a BigQuery en modo Importar. - 4 datasets independientes, sin relaciones formales. - Página 1 (Visión general): 4 KPIs, slicer temporal, gráfico de líneas, ranking de distritos. - Página 2 (Mercado): treemap por room_type, comparativa Navidad vs resto, top 10 barrios con slicer de segmento. - Página 3 (Clima): 3 visuales filtrados por métrica, nota didáctica sobre confounding temporal. - 4 medidas DAX: Listings totales, Noches totales, % Ocupación, Pico ocupación diaria.

---

4. Los tres modelos explicados

Logistic Regression (Regresión Logística)

Qué es: modelo lineal que estima la probabilidad de la clase positiva mediante la función sigmoide aplicada a una combinación lineal de las features.

Fórmula simplificada: P(y=1|x) = 1 / (1 + e^(-z)) donde z = w0 + w1*x1 + w2*x2 + ...

Hiperparámetros usados: - Regularización: L2 (Ridge), C=1. - max_iter: 1000. - class_weight: desmarcado.

Por qué se incluye: referencia (baseline). Es rápido, sus coeficientes son interpretables y sirve como suelo mínimo de rendimiento.

Resultado: F1=0.785, AUC=0.891 en Orange. Sorpresivamente alto comparado con sklearn (0.514, 0.629); la diferencia se explica por el preprocessing automático de Orange y el class_weight='balanced' que sí estaba activo en sklearn.

Random Forest

Qué es: ensemble basado en bagging. Entrena múltiples árboles de decisión sobre subconjuntos aleatorios del dataset y de las features. Agrega las predicciones por votación mayoritaria (clasificación) o media (regresión).

Por qué funciona: la diversidad de los árboles reduce la varianza y captura interacciones no lineales sin requerir feature engineering manual.

Hiperparámetros usados: - n_estimators: 200 (más árboles → más estable, más lento). - max_depth: 15 (limita la profundidad para evitar overfitting). - min_samples_leaf: 5 (hojas mínimas para evitar fragmentación). - random_state: 42 (reproducibilidad).

Por qué es el ganador: equilibra precision y recall mejor que los otros dos. Los errores son simétricos (28k FP vs 20k FN). Es robusto a hiperparámetros y captura la señal del listing_te mejor que la regresión lineal.

Resultado: AUC=0.895, F1=0.812.

Gradient Boosting

Qué es: ensemble basado en boosting iterativo. Cada árbol nuevo se entrena para corregir los errores residuales del conjunto de árboles anteriores. Es la base de algoritmos modernos como XGBoost, LightGBM, CatBoost.

Por qué funciona: la corrección iterativa permite alcanzar precisión muy alta. Suele ser uno de los modelos más fuertes en datos tabulares.

Hiperparámetros usados: - n_estimators: 200. - learning_rate: 0.10 (peso de cada árbol nuevo). - max_depth: 5 (árboles superficiales que se combinan). - min_samples_split: 2 (default).

Por qué no gana: muy pegado al RF (AUC 0.893 vs 0.895). En datos donde la señal está concentrada en una feature dominante (listing_te), todos los modelos ensembles dan resultados similares.

Resultado: AUC=0.893, F1=0.804.

---

5. Métricas de evaluación con explicación didáctica

Matriz de confusión

Es una tabla 2×2 que cruza predicciones con realidad:

Real positivo

Real negativo

De la matriz se derivan todas las demás métricas.

Accuracy (precisión global)

Accuracy = (TP + TN) / Total

Qué mide: porcentaje de aciertos sobre el total.

Cuándo es engañosa: cuando las clases están desbalanceadas. Si el 95% de los datos son negativos, predecir siempre “negativo” da 95% de accuracy pero el modelo no sirve.

En el proyecto: RF acierta el 81,2% de las predicciones. Es buena porque las clases están casi balanceadas (55/45).

Precision

Precision = TP / (TP + FP)

Qué mide: de los que predigo positivos, cuántos lo son de verdad.

Cuándo importa: cuando los falsos positivos son costosos. Ej: si etiqueto un email como spam y no lo es, el usuario pierde un email importante.

En el proyecto: 78,7% en RF. De cada 100 noches que predigo como ocupadas, 79 lo están realmente.

Recall (sensibilidad)

Recall = TP / (TP + FN)

Qué mide: de los positivos reales, cuántos detecto.

Cuándo importa: cuando los falsos negativos son costosos. Ej: en un test médico de cáncer, no detectar un caso real es muy grave.

En el proyecto: 84,2% en RF. De cada 100 noches realmente ocupadas, detecto 84.

F1-score

F1 = 2 × (Precision × Recall) / (Precision + Recall)

Qué mide: media armónica de precision y recall. Penaliza los extremos: si una de las dos es muy baja, el F1 baja mucho.

Por qué se usa en lugar de accuracy: robusto al desbalanceo.

En el proyecto: 0.812 en RF. Indica un buen equilibrio entre precision y recall.

AUC-ROC

ROC = Receiver Operating Characteristic. Es una curva que dibuja, para todos los umbrales de decisión posibles: - Eje X: **FPR** (False Positive Rate) = FP / (FP + TN). Tasa de falsos positivos sobre los negativos reales. - Eje Y: **TPR** (True Positive Rate, igual que recall) = TP / (TP + FN). Tasa de verdaderos positivos sobre los positivos reales.

Cómo se construye: se varía el threshold desde 1.0 (siempre predice negativo, punto (0,0)) hasta 0.0 (siempre predice positivo, punto (1,1)). Cada threshold genera un punto en la curva.

Esquinas de referencia: - (0,0): nunca predice positivo. 0 TP, 0 FP. - (1,1): siempre predice positivo. Detecta todo, falla en todo lo negativo. - (0,1): clasificador perfecto. Detecta todo sin falsos positivos. - Diagonal (línea negra punteada): clasificador aleatorio.

AUC = Area Under the Curve. Va de 0.5 (aleatorio) a 1.0 (perfecto).

AUC

< 0.6

0.6-0.7

0.7-0.8

0.8-0.9

0.9-1.0

En el proyecto: AUC=0.895 en RF. Indica que si tomamos al azar una noche realmente ocupada y una realmente libre, el modelo da una probabilidad mayor a la ocupada el 89,5% de las veces.

MCC (Matthews Correlation Coefficient)

MCC = (TP·TN - FP·FN) / sqrt((TP+FP)(TP+FN)(TN+FP)(TN+FN))

Qué mide: correlación entre predicciones y etiquetas reales. Va de -1 (totalmente equivocado) a +1 (perfecto), 0 = aleatorio.

Por qué se usa: muy robusta al desbalanceo. Solo es alta si el modelo acierta bien en las cuatro celdas de la matriz de confusión.

En el proyecto: 0.627 en RF. Indica una correlación positiva clara.

---

6. Las 25 preguntas más probables del profesor

Sobre el problema y el pivot

1. ¿Qué predice tu modelo? Predice si una noche concreta de un piso turístico de Barcelona estará reservada/bloqueada (1) o libre (0). Es clasificación binaria supervisada.

2. ¿Por qué cambiaste de Predictor de Precio a Predictor de Ocupación? Porque la columna price del dataset Inside Airbnb está 100% vacía desde finales de 2024 por restricciones legales aplicadas por la plataforma. Lo descubrí en la fase de Data Understanding y decidí pivotar la tarea para mantener el resto del stack y la metodología.

3. ¿Cuál es la variable target? La columna occupied, derivada de available del calendar.csv: vale 1 si available='f' (no disponible) y 0 si available='t'.

Sobre la metodología

4. ¿Qué es CRISP-DM? Cross-Industry Standard Process for Data Mining. Metodología estándar para proyectos de ciencia de datos, con seis fases: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation y Deployment.

5. ¿Cómo aplicaste CRISP-DM? Cada fase tiene su entregable identificable en el repo: notebooks 02-05 cubren Data Understanding, Preparation y Modeling; los entregables de Evaluation están en orange/images/ y en el notebook 05; el Deployment se materializa en BigQuery + Power BI.

Sobre los datos

6. ¿De dónde vienen los datos? De cuatro fuentes: Inside Airbnb (listings y calendar), Open-Meteo (clima), Ticketmaster (eventos, no integrado finalmente) y una lista manual de festivos catalanes.

7. ¿Cuántas filas tiene el dataset modelado? 1.012.783 filas, una por combinación de los 18.172 listings con cada uno de los 56 días del horizonte (14/12/2025 a 07/02/2026).

8. ¿Qué problemas encontraste en los datos? Tres: la columna price vacía, la ambigüedad de available='f' (mezcla reservas con bloqueos del anfitrión) y el desfase temporal de Ticketmaster (eventos disponibles solo de Abr-Jul 2026).

9. ¿Cómo limpiaste los datos? Imputación de nulos por mediana de barrio, conversión de booleanos t/f a 1/0, categorización del weathercode en cuatro grupos, filtrado del calendario al horizonte de 8 semanas.

Sobre el modelado

10. ¿Qué algoritmos usaste y por qué? Tres: Logistic Regression como referencia lineal, Random Forest como ensemble basado en bagging y Gradient Boosting como ensemble basado en boosting iterativo. Son los tres clasificadores más representativos del estado del arte para datos tabulares.

11. ¿Por qué split temporal y no aleatorio? Para simular un escenario realista de predicción: el modelo se entrena con el pasado y se evalúa con el futuro. El test cae además fuera de temporada alta, lo que añade exigencia.

12. ¿Qué es leakage y cómo lo evitaste? Es cuando una feature contiene información del target. Las columnas availability_30/60/90/365 y estimated_occupancy_l365d vienen del propio calendar.csv y son proxies directos del target. Las eliminé explícitamente del feature set. Sin ese filtro daban AUC tramposo > 0.93.

13. ¿Qué es target encoding? Codificar una categoría como la media del target en ese grupo. Calculo listing_te como la media de occupied por listing y neigh_enc como la media por barrio. Las calculo solo sobre datos de train para no contaminar el test.

14. ¿Por qué usas one-hot encoding? Porque los algoritmos de ML no consumen strings directamente. One-hot convierte una variable categórica con N valores en N columnas binarias 0/1, sin imponer un orden artificial entre categorías.

15. ¿Cuál es el modelo ganador y con qué métricas? Random Forest, con AUC=0.895 y F1=0.812 en el conjunto de test. Supera los umbrales del curso (F1 ≥ 0.75 y AUC ≥ 0.80) con holgura.

16. ¿Qué feature es más importante? listing_te (target encoding por listing) con importance 0.66 sobre 1.0. La popularidad histórica del piso es el mejor predictor de su ocupación futura.

Sobre la evaluación

17. ¿Qué diferencia hay entre F1 y AUC? F1 mide el rendimiento en un threshold concreto (0.5 por defecto). AUC mide la capacidad discriminativa del modelo en todos los thresholds. AUC es más robusta al desbalanceo de clases y a la elección del threshold.

18. ¿Cómo lees una matriz de confusión? Es una tabla 2×2 con clase real en las filas y predicha en las columnas. La diagonal son aciertos (TP y TN), las celdas off-diagonal son errores (FP y FN).

19. ¿Qué es la curva ROC? Curva que muestra la tasa de verdaderos positivos vs la tasa de falsos positivos para todos los thresholds posibles. El área bajo la curva (AUC) es una métrica escalar de capacidad discriminativa.

Sobre el deployment

20. ¿Por qué BigQuery? Por tres razones: free tier generoso (1 TB queries/mes, 10 GB almacenamiento), conector nativo a Power BI y escalabilidad sin cambios de arquitectura.

21. ¿Por qué Power BI? Por su conector nativo a BigQuery, su soporte de medidas DAX, sus slicers interactivos y su gratuidad en versión Desktop. Permite a usuarios no técnicos explorar el dato sin programar.

22. ¿Qué páginas tiene tu dashboard? Tres: Visión general (KPIs, evolución, ranking distritos), Mercado (treemap, comparativa Navidad vs resto, top 10 barrios) y Clima (efecto del tiempo con nota didáctica sobre confounding).

23. ¿Qué es el confounding temporal de la página de Clima? Aparentemente “con lluvia” tiene más ocupación que “sin lluvia”. No es causalidad: los días lluviosos coinciden con la semana de Navidad, donde la demanda turística es estructuralmente mayor. La fecha es la variable confusora oculta. Es un ejemplo de “correlación no implica causalidad”.

Sobre alternativas y limitaciones

24. ¿Qué harías diferente con más tiempo? Probaría XGBoost o LightGBM (suelen dar 1-3 puntos extra en AUC), construiría un modelo específico para listings nuevos sin historial (cold start), ampliaría el horizonte temporal acumulando varios scrapes mensuales y desplegaría el modelo como API REST.

25. ¿Qué limitaciones tiene tu modelo? Cuatro: la ambigüedad intrínseca de available='f' (mezcla reserva con bloqueo), la dependencia del listing_te que no funciona en cold start, el horizonte limitado a 56 días que no permite extrapolar a otras temporadas, y el sesgo del primer día del scrape (~76% ocupación artificial por bloqueos previos).

---

7. Frases preparadas para defender decisiones

Frases sobre metodología

- *"Apliqué CRISP-DM de forma estricta. Cada fase tiene su entregable identificable en el repositorio."*
- *"El proyecto siguió la metodología CRISP-DM, lo cual permitió que el pivot de la fase de Business Understanding no destruyera el trabajo posterior."*
- *"La separación clara entre Business Understanding y Data Understanding permitió detectar el problema de la columna price antes de implementar nada."*

Frases sobre los datos

- *"El dataset combina cuatro fuentes heterogéneas integradas mediante joins en pandas con granularidad listing × día."*
- *"Documenté tres hallazgos críticos en la fase exploratoria que condicionaron las decisiones posteriores del modelado."*
- *"El horizonte se limita a 8 semanas posteriores al scrape para mitigar el sesgo de bloqueos del anfitrión."*

Frases sobre el modelado

- *"Usé split temporal en lugar de aleatorio para simular un escenario realista de predicción."*
- *"Apliqué target encoding solo sobre los datos de train, evitando data leakage hacia el conjunto de test."*
- *"Eliminé explícitamente las columnas availability_* por ser proxies directos del target. Es una decisión metodológica importante."*
- *"Implementé el pipeline en dos plataformas independientes (sklearn y Orange) para validar de manera cruzada la consistencia de los resultados."*

Frases sobre la evaluación

- *"El modelo ganador, Random Forest, supera con holgura los dos umbrales del curso: F1=0.812 y AUC=0.895."*
- *"La matriz de confusión muestra errores casi simétricos, lo cual indica un modelo equilibrado sin sesgo grave hacia ninguna clase."*
- *"La feature más predictiva es listing_te con importance 0.66, capturando la popularidad histórica intrínseca del piso."*

Frases sobre las limitaciones

- *"El modelo se beneficia mucho del target encoding por listing, lo cual implica que su rendimiento degradaría con listings completamente nuevos. Esta limitación, conocida como cold start, queda documentada."*
- *"La columna available de Inside Airbnb mezcla noches reservadas con noches bloqueadas por el anfitrión. Esta ambigüedad es intrínseca al dataset y no se puede resolver sin acceso al backend de Airbnb."*
- *"El horizonte está limitado a 56 días que cubren temporada navideña. Las conclusiones no son extrapolables directamente a verano u otras temporadas."*

Frases para responder a "¿está desplegado en producción?"

- *"El alcance del curso llega a Deployment como dashboard analítico, no como API. El modelo se entrena offline y los resultados se presentan en Power BI conectado a BigQuery."*
- *"Para producción real, desplegaría el modelo como endpoint REST con FastAPI o como función serverless en Google Cloud Run. Es una línea de mejora futura documentada."*

Bonus: errores típicos a evitar en la defensa

1. **No leas la memoria palabra por palabra.** El profe ya la tiene. Tu rol es comentarla.
2. **No te entretengas en código.** Si el profe pregunta por una función concreta, abre el notebook; si no, no hace falta.
3. **No prometas lo que no hay.** Si te pregunta si has hecho XGBoost y no lo has hecho, dilo claro.
4. **No empieces por la solución.** Empieza por el problema (el pivot) — eso engancha y demuestra criterio.
5. **Si te bloqueas, vuelve al README principal.** Es tu mapa de navegación.
6. **No digas "muy bueno" sin cifras.** Di "AUC 0.895, dentro del rango bueno-excelente según la escala estándar".
7. **No confundas precision con accuracy.** Son métricas distintas con interpretaciones diferentes.
8. **No olvides mencionar la dualidad sklearn/Orange.** Es un punto fuerte que el profe valorará.

Última frase para cerrar la defensa

> *"Para resumir: el proyecto sigue CRISP-DM en sus seis fases, integra cuatro fuentes de datos heterogéneas, entrena tres modelos en dos plataformas independientes y supera los umbrales del curso con holgura. El Random Forest, con AUC=0.895 y F1=0.812, demuestra que la popularidad histórica de cada piso es el mejor predictor de su ocupación futura. El sistema completo está documentado en cuatro READMEs jerarquizados, los resultados se almacenan en BigQuery y se presentan en un dashboard interactivo de Power BI consumible por usuarios no técnicos. Quedo abierto a preguntas."*